UNIVERSITAS MIKROSKIL

LAPORAN UJIAN TENGAH SEMESTER

MILESTONE 1

Pola Penggunaan Perangkat Rumah Pintar

Pendekatan Clustering (Unsupervised Learning)

IF2116 Pembelajaran Mesin

Project ID: B04 | Kelas: IF-B PAGI

Dosen Pengampu: Al Hamidy

No	NIM	Nama Anggota
1	231112081	Ipaldi Sembiring
2	231112313	Mikkael Raynala Tampubolon
3	231112747	Muhammad Dhani Irvansyah

November 2026

Ringkasan

Laporan ini memuat Milestone 1 project Pola Penggunaan Perangkat Rumah Pintar (Project ID B04) dengan pendekatan clustering. Data berasal dari satu rumah pintar, berisi konsumsi daya perangkat dan variabel cuaca selama sekitar 350 hari. Setelah pembersihan dan agregasi per jam, diperoleh 8.399 observasi dan 22 fitur. K-Means dijadikan baseline, sedangkan Gaussian Mixture Model (GMM) dan Agglomerative Clustering menjadi model kandidat. Evaluasi memakai hold-out 80/20 dan 5-Fold Cross-Validation dengan metrik Silhouette, Davies-Bouldin, dan Calinski-Harabasz.

Temuan utama: (1) tidak ada model yang unggul pada semua metrik dan nilai Silhouette semua model rendah (di bawah sekitar 0,17), sehingga struktur cluster belum tegas; (2) ketiga model membentuk kelompok yang sangat berbeda (K-Means terutama memisahkan musim dan pemanas, GMM memisahkan jam aktif dan jam sepi, Agglomerative memisahkan jam berawan); (3) fitur cuaca sangat memengaruhi pengelompokan, padahal hanya pemanas, Wine cellar, dan Fridge yang berkorelasi dengan suhu; (4) K-Means paling stabil antar fold, sedangkan GMM dengan k=3 paling tidak stabil. Model final belum diputuskan pada tahap ini.

Seluruh angka pada laporan ini berasal dari notebook eksperimen yang dikumpulkan bersama laporan (B04_PolaPenggunaanPerangkatRumahPintar_UTS_Milestone1.ipynb) dan dapat dijalankan ulang dengan random_state = 42. Huruf bagian notebook (misalnya "bagian R") digunakan sebagai rujukan silang ke notebook.

A. Problem Formulation

A.1 Latar Belakang dan Alasan Masalah Penting

Penelitian tentang rumah berkelanjutan didorong oleh kenaikan harga energi dan kekhawatiran terhadap perubahan iklim [1]. Data konsumsi listrik rumah tangga berskala halus dapat dimanfaatkan untuk memahami penggunaan energi, tetapi pola di dalamnya tidak terlihat langsung dari data mentah. Teknik clustering digunakan dalam penelitian beban listrik untuk menggali pola konsumsi energi yang mendasarinya, dan berbagai algoritma seperti K-Means, hierarchical, dan Gaussian Mixture Model telah dibandingkan untuk keperluan ini [2]. Project ini menerapkan pendekatan serupa pada data satu rumah pintar untuk mengenali pola penggunaan perangkatnya.

A.2 Rumusan Masalah

Pola penggunaan perangkat listrik pada sebuah rumah pintar berbeda-beda menurut waktu dan kondisi cuaca, tetapi pola tersebut belum diketahui secara jelas dari data konsumsi mentah. Tanpa pemahaman pola ini, sulit mengidentifikasi kebiasaan penggunaan energi dan peluang penghematan.

A.3 Tujuan, Target, dan Pendekatan

- **Tujuan:** mengelompokkan jam-jam penggunaan listrik rumah pintar ke dalam cluster dengan karakteristik konsumsi perangkat yang serupa, lalu menafsirkan setiap cluster sebagai pola penggunaan perangkat.
- **Target dan keluaran:** tidak ada target (label) karena masalah bersifat unsupervised. Keluaran yang diharapkan adalah label cluster untuk setiap jam beserta profil karakteristik tiap cluster.
- **Pendekatan machine learning:** unsupervised learning (clustering) dengan K-Means sebagai baseline, GMM dan Agglomerative Clustering sebagai kandidat, serta PCA sebagai bahan uji reduksi dimensi.

A.4 Batasan Proyek

- Data berasal dari satu rumah (satu lokasi dan satu periode sekitar 350 hari), sehingga hasil tidak digeneralisasi ke rumah lain.
- Pendekatan hanya classical machine learning (K-Means, GMM, Agglomerative Clustering, dan PCA), sesuai ruang lingkup mata kuliah.

- Masalah bersifat tanpa label, sehingga kualitas cluster dinilai dengan metrik internal dan interpretasi manual, bukan akurasi.
- Unit observasi adalah satu jam hasil agregasi dari data per menit. Interval waktu dan zona waktu merupakan asumsi dari pola data.
- Project ini mengelompokkan pola penggunaan, bukan memprediksi konsumsi. Dataset dan masalah tidak diganti selama proyek.
- Pada Milestone 1, tuning menyeluruh dan pemilihan model final belum dilakukan.

B. Dataset dan Data Understanding

B.1 Sumber dan Struktur

Dataset yang digunakan adalah *Smart Home Dataset with Weather Information* (Kaggle, pengunggah taranvee), file HomeC.csv [3]. URL: https://www.kaggle.com/datasets/taranvee/smart-home-dataset-with-weather-information. Dataset diunduh otomatis lewat pustaka kagglehub pada sel pertama notebook dan tidak dimodifikasi secara manual.

Karakteristik	Keterangan
Jumlah observasi mentah	503.911 baris dan 32 kolom (503.910 baris valid)
Unit observasi mentah	Satu baris per menit (asumsi, lihat B.3 nomor 1)
Unit observasi untuk modeling	Satu jam (rata-rata dari data per menit): 8.399 observasi
Rentang waktu	Sekitar 350 hari (1 Januari sampai 15 Desember 2016, waktu lokal berdasarkan asumsi UTC-5)
Target	Tidak ada (unsupervised learning)

B.2 Deskripsi Fitur

Dari 32 kolom mentah, 22 fitur digunakan untuk pemodelan:

Kelompok	Fitur	Deskripsi	Satuan
Perangkat (13)	Dishwasher, Furnace 1, Furnace 2, Home office, Fridge, Wine cellar, Garage door, Kitchen 12, Kitchen 14, Barn, Well, Microwave, Living room	Rata-rata daya listrik per jam pada sirkuit atau perangkat yang bersangkutan	kW (dari nama kolom)
Cuaca (6)	temperature	Suhu luar	dugaan derajat Fahrenheit (rentang sekitar 20 sampai 80)
	humidity	Kelembapan relatif	pecahan 0 sampai 1
	windSpeed	Kecepatan angin	dugaan mph
	cloudCover	Tutupan awan	pecahan 0 sampai 1
	pressure	Tekanan udara	dugaan milibar (sekitar 1.010 sampai 1.020)
	visibility	Jarak pandang	dugaan mil
Waktu (3, hasil feature engineering)	hour_sin, hour_cos	Jam dalam sehari yang diubah ke sin dan cos agar jam 23 dan jam 0 berdekatan	tanpa satuan
	weekend	Penanda akhir pekan (1 = Sabtu atau Minggu, 0 = hari kerja)	biner

Satuan cuaca ditulis sebagai dugaan karena dibaca dari rentang nilai, bukan dari dokumentasi dataset. Kolom yang tidak dipakai: use dan gen (use identik dengan House overall dan gen identik dengan Solar, sehingga redundan atau bukan penggunaan perangkat), Kitchen 38 (hampir selalu nol), apparentTemperature, windBearing, precipIntensity, dewPoint, dan precipProbability (tidak dipilih untuk penyederhanaan), serta icon dan summary (teks yang mengulang informasi cuaca).

B.3 Kualitas Data

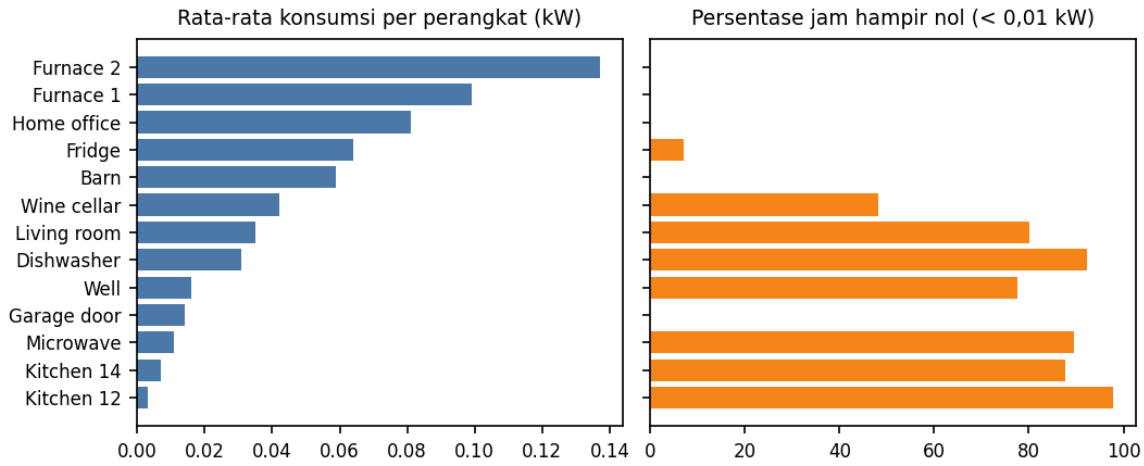
Pemeriksaan data mentah (notebook bagian B) menemukan masalah berikut:

1. **Kolom time tidak valid.** Berisi Unix timestamp yang naik 1 per baris, sehingga jika dibaca apa adanya hanya mencakup sekitar 5,8 hari. Dari jumlah baris (503.910 / 1.440 = sekitar 350 hari) dan cuaca yang berubah rata-rata tiap sekitar 58 baris, disimpulkan bahwa 1 baris = 1 menit. Ini asumsi berdasarkan pola data, bukan keterangan resmi dataset.
2. **Satu baris terakhir tidak valid** (time berisi karakter "\" dan semua kolom lain kosong). Ini satu-satunya baris dengan nilai hilang.
3. **cloudCover bertipe teks** karena ada 58 baris yang berisi kata "cloudCover" (header yang terselip).
4. **Kolom kembar:** use identik dengan House overall, dan gen identik dengan Solar.
5. **Kitchen 38** hampir selalu nol (rata-rata sekitar 0,000009 kW).
6. **Tidak ada data duplikat.**
7. **Cakupan perangkat tidak lengkap:** jumlah konsumsi semua perangkat hanya berkorelasi 0,66 dengan use, sehingga tidak semua beban rumah tercatat per perangkat.

C. EDA dan Initial Findings

Eksplorasi dilakukan secara deskriptif pada seluruh 8.399 jam hasil agregasi. Tidak ada model yang dilatih pada tahap ini sehingga tidak ada kebocoran data. Waktu memakai asumsi zona UTC-5.

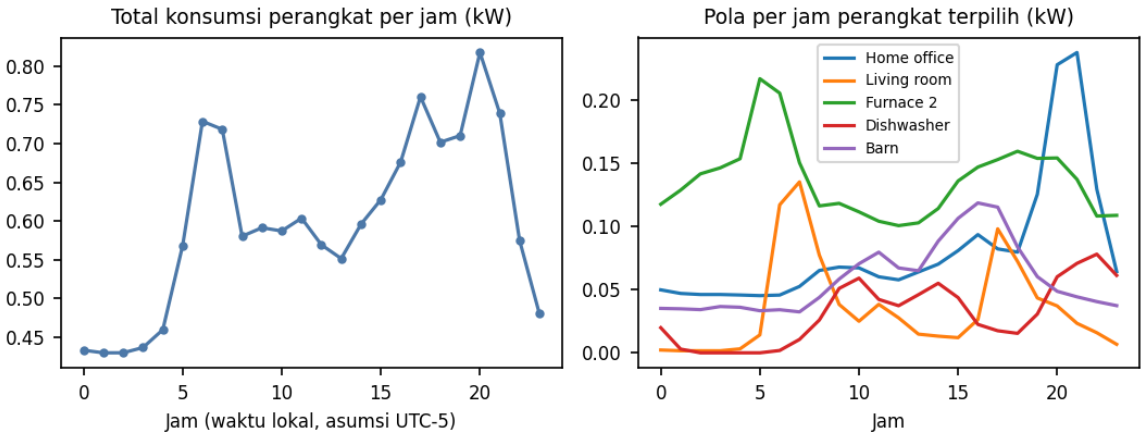
C.1 Dominasi dan Sebaran Perangkat



Gambar 1. Rata-rata konsumsi dan persentase jam hampir nol per perangkat.

- Pemanas mendominasi konsumsi: Furnace 2 (0,137 kW, 22,8% dari total rata-rata perangkat) dan Furnace 1 (0,099 kW, 16,6%) bersama-sama 39,4%. Berikutnya Home office (13,6%), Fridge (10,6%), dan Barn (9,8%).
- Banyak perangkat hampir selalu mati: Kitchen 12 (97,7% jam di bawah 0,01 kW), Dishwasher (92,4%), Microwave (89,6%), Kitchen 14 (87,6%), dan Living room (80,2%).
- Sebaran sangat miring: skewness Microwave 8,8, Kitchen 12 8,0, dan Barn 6,1. Garage door hampir konstan (median 0,013 kW, simpangan baku 0,006) tetapi memiliki skewness 26,4 karena lonjakan yang sangat jarang.

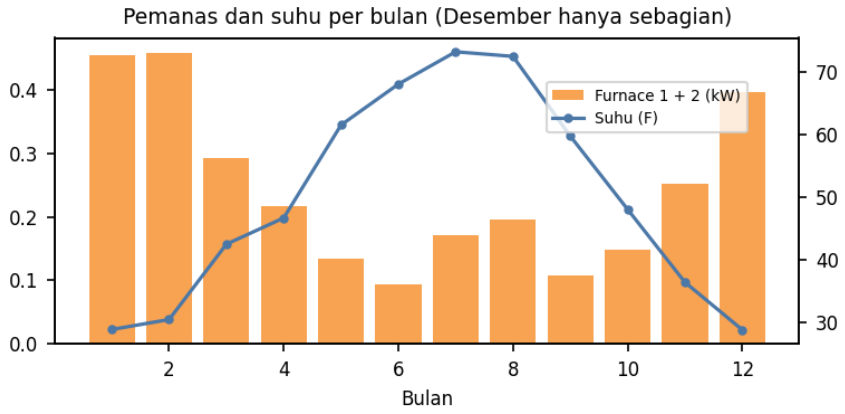
C.2 Pola dalam Sehari, Hari Kerja, dan Akhir Pekan



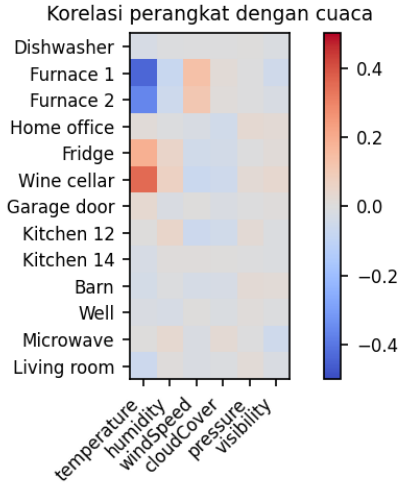
Gambar 2. Pola konsumsi per jam dalam sehari.

- Konsumsi total terendah pada dini hari (sekitar 0,43 kW) dan tertinggi pukul 20 (0,818 kW). Ada puncak pagi pukul 6 sampai 7 (sekitar 0,72 sampai 0,73 kW) dan puncak sore sampai malam pukul 17 sampai 21.
- Total konsumsi hari kerja (0,595 kW) dan akhir pekan (0,607 kW) hampir sama. Perbedaan ada pada perangkat tertentu: Barn 1,54 kali lebih tinggi pada akhir pekan, sedangkan Living room (0,76 kali), Home office (0,81 kali), dan Microwave (0,83 kali) lebih rendah.

C.3 Pola Musim dan Cuaca



Gambar 3. Rata-rata Furnace 1 + 2 dan suhu per bulan.



Gambar 4. Korelasi antara konsumsi perangkat dan variabel cuaca.

- Pemanas sangat musiman: pada Januari (suhu rata-rata 28,8 F) Furnace 1 dan 2 totalnya sekitar 0,455 kW, sedangkan pada Juni (68,1 F) hanya sekitar 0,093 kW. Desember hanya berisi 359 jam.
- Korelasi dengan suhu: Furnace 1 -0,44, Furnace 2 -0,36, Wine cellar 0,35, dan Fridge 0,19. Perangkat lain hampir tidak berkorelasi dengan cuaca (nilai mutlak di bawah sekitar 0,07).

C.4 Implikasi terhadap Masalah dan Tujuan

- Hanya pemanas, Wine cellar, dan Fridge yang dipengaruhi cuaca. Karena itu clustering dengan fitur cuaca cenderung membentuk kelompok musim dan cuaca berawan, bukan pola penggunaan perangkat (terbukti pada hasil K-Means dan seleksi fitur di bagian E dan H).
- Mayoritas perangkat bersifat jarang (sparse) dan sangat miring, sehingga kelompok aktivitas (misalnya Dishwasher dan Kitchen 12) kecil dan nilai ekstrem berpengaruh pada cluster berbasis jarak.
- Pola penggunaan berbeda menurut jam, sehingga fitur waktu secara teori relevan. Namun perbedaan hari kerja dan akhir pekan kecil, sejalan dengan temuan bahwa fitur waktu hampir tidak mengubah hasil cluster.
- Garage door hampir konstan dan kurang informatif sebagai fitur, sehingga menjadi kandidat untuk dibuang pada tahap berikutnya.

D. Preprocessing

D.1 Langkah dan Alasan

No	Langkah	Alasan
1	Membuang baris terakhir yang tidak valid	Semua kolomnya kosong
2	Merekonstruksi kolom waktu dengan interval 1 menit dan menggesernya 5 jam ke waktu lokal (asumsi UTC-5)	Timestamp asli naik 1 per baris sehingga tidak mencerminkan waktu sebenarnya
3	Mengubah cloudCover ke tipe angka	58 nilai teks yang terselip menjadi kosong, lalu diabaikan saat dirata-ratakan per jam
4	Membuang kolom kembar House overall dan Solar	Identik dengan use dan gen
5	Memilih fitur: 13 perangkat dan 6 variabel cuaca	use adalah total (redundan), gen adalah produksi listrik, Kitchen 38 hampir selalu nol, icon dan summary berupa teks yang mengulang cuaca
6	Agregasi rata-rata per jam	Data per menit (503.910 baris) terlalu besar untuk Agglomerative, dan pola penggunaan lebih bermakna pada skala jam
7	Menambah fitur waktu: hour_sin, hour_cos, weekend	Jam bersifat siklik, dan pola hari kerja dan akhir pekan dapat berbeda
8	Membagi data secara acak 80% latih dan 20% uji (random_state = 42)	Untuk menguji generalisasi pada data yang tidak dipakai melatih
9	Standardisasi (StandardScaler)	K-Means dan model berbasis jarak sensitif terhadap perbedaan skala antar fitur

D.2 Pencegahan Data Leakage

StandardScaler hanya dilatih (fit) pada data latih, lalu diterapkan ke data uji. Pada PCA dan 5-Fold Cross-Validation, scaler (dan PCA) dilatih ulang di dalam Pipeline atau di dalam setiap fold hanya dari bagian latih. Langkah pembersihan lain (membuang kolom kembar, merekonstruksi waktu, agregasi per jam, dan fitur waktu) bekerja per baris atau per jam dan tidak mempelajari parameter dari data, sehingga tidak menimbulkan kebocoran data.

D.3 Data Setelah Preprocessing

Unit observasi adalah satu jam (8.399 observasi tanpa nilai hilang) dengan 22 fitur (13 perangkat, 6 cuaca, 3 waktu). Data latih berisi 6.719 jam dan data uji 1.680 jam.

E. Initial Feature Engineering

E.1 Fitur yang Dibentuk atau Ditransformasi

Langkah	Alasan	Dampak yang terlihat
Agregasi per jam (rata-rata dari data per menit)	Data per menit terlalu besar untuk Agglomerative, dan pola penggunaan lebih bermakna pada skala jam	Menghasilkan 8.399 observasi tanpa nilai hilang
hour_sin dan hour_cos dari jam dalam sehari	Jam bersifat siklik (jam 23 dekat dengan jam 0), sehingga tidak tepat dipakai sebagai angka biasa	EDA menunjukkan pola harian yang jelas; namun menghapus fitur waktu hanya sedikit mengubah hasil cluster (ARI 0,91 sampai 0,94 pada Tabel 1)
weekend (penanda akhir pekan)	Pola hari kerja dan akhir pekan dapat berbeda	Total konsumsi hampir sama (0,595 dan 0,607 kW); hanya perangkat tertentu yang berbeda, misalnya Barn
Standardisasi (StandardScaler)	Metode berbasis jarak dan varians sensitif terhadap perbedaan skala	Dilatih hanya pada data latih untuk mencegah kebocoran data
Seleksi fitur (membuang use, gen, Kitchen 38, dan kolom cuaca lain; membandingkan dengan dan tanpa cuaca)	use dan gen redundan, Kitchen 38 hampir selalu nol, dan peran cuaca perlu diuji	Cuaca mengubah pengelompokan secara besar (ARI sekitar 0,35 sampai 0,51 tanpa cuaca), sehingga peran cuaca diputuskan setelah UTS

E.2 Uji Kumpulan Fitur (Seleksi Fitur Awal)

K-Means (n_init = 10, random_state = 42, scaling di dalam Pipeline) dijalankan dengan empat kumpulan fitur. Agar adil, semua hasil dinilai pada ruang yang sama, yaitu 13 fitur perangkat yang terstandar, karena Silhouette tidak boleh dibandingkan antar ruang fitur yang berbeda. Kemiripan dengan hasil memakai semua fitur diukur dengan Adjusted Rand Index (ARI).

k	Skenario fitur	Jumlah fitur	Silhouette	Davies-Bouldin	Calinski-Harabasz	ARI vs semua fitur
3	Semua fitur (22)	22	0,036	5,795	260,3	1,000
3	Tanpa cuaca (16)	16	0,171	2,113	717,4	0,351
3	Tanpa waktu (19)	19	0,038	5,771	257,6	0,938
3	Hanya perangkat (13)	13	0,177	2,060	722,9	0,354
5	Semua fitur (22)	22	0,061	3,655	477,6	1,000
5	Tanpa cuaca (16)	16	0,196	1,659	712,2	0,513
5	Tanpa waktu (19)	19	0,055	3,629	476,4	0,910
5	Hanya perangkat (13)	13	0,214	1,597	756,4	0,491

Tabel 1. Hasil uji kumpulan fitur pada K-Means (k = 3 dan 5), dinilai pada ruang 13 fitur perangkat.

- Fitur cuaca mengubah pengelompokan secara besar: tanpa cuaca, ARI terhadap hasil semua fitur hanya sekitar 0,35 (k=3) dan 0,51 (k=5). Cluster berawan dan lembap hilang ketika cuaca dibuang.
- Fitur waktu hampir tidak berpengaruh: tanpa waktu, ARI 0,938 (k=3) dan 0,910 (k=5), dan metrik hampir sama.
- Cluster berbasis perangkat lebih jelas jika cuaca dibuang (pada k=5 terbentuk jam sepi, jam pemanas tinggi, jam aktif ruang tamu dan dapur, jam Dishwasher aktif, dan satu cluster kecil Kitchen 12).
- **Peringatan:** nilai Silhouette yang jauh lebih tinggi pada skenario tanpa cuaca sebagian disebabkan evaluasi dilakukan pada ruang perangkat, yaitu ruang yang juga dipakai skenario itu untuk membentuk cluster. Angka ini tidak membuktikan bahwa tanpa cuaca lebih baik secara umum.

F. Baseline dan Initial Candidate Models

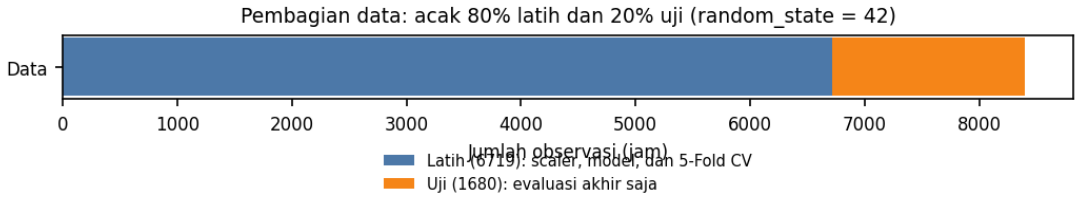
Peran	Model	Konfigurasi	Alasan pemilihan
Baseline	K-Means	n_init = 10, random_state = 42, k = 2 dan 3	Sederhana, cepat, dan mudah diinterpretasi; sesuai contoh baseline untuk unsupervised learning
Kandidat 1	Gaussian Mixture Model (GMM)	covariance_type = full, n_init = 5, random_state = 42, k = 2 dan 3	Mengizinkan cluster lonjong, berukuran berbeda, dan saling tumpang tindih; relevan karena Silhouette baseline rendah (sekitar 0,10); menyediakan BIC dan AIC
Kandidat 2	Agglomerative Clustering	linkage = ward, k = 2 dan 3	Clustering hierarkis yang tidak mengasumsikan cluster bulat dan tidak bergantung pada inisialisasi acak; berbeda pendekatan dari K-Means dan GMM

Semua model dilatih hanya pada data latih (6.719 jam) dengan 22 fitur terstandar. Agglomerative Clustering tidak memiliki fungsi prediksi untuk data baru, sehingga label data uji ditentukan lewat centroid terdekat dari cluster data latih.

Ukuran cluster pada data latih: K-Means k=2: 2.343 dan 4.376 jam, k=3: 3.748, 1.953, dan 1.018 jam. GMM k=2: 2.368 dan 4.351 jam, k=3: 1.828, 3.848, dan 1.043 jam. Agglomerative k=2: 5.887 dan 832 jam, k=3: 4.338, 1.549, dan 832 jam.

G. Evaluation Design

G.1 Pembagian Data dan Metode Validasi



Gambar 5. Diagram pembagian data (hold-out 80/20) dan penggunaan tiap bagian.

- **Hold-out:** pembagian acak 80% data latih (6.719 jam) dan 20% data uji (1.680 jam), random_state = 42. Indeks data latih dan data uji saling lepas.
- **5-Fold Cross-Validation** pada data latih (KFold dengan shuffle = True, random_state = 42). Pada setiap fold, scaler dan model dilatih hanya pada 4 lipatan, lalu lipatan ke-5 diberi label dan dinilai. Karena project ini tanpa target, yang diukur adalah kestabilan metrik antar fold, bukan akurasi.
- **Validation set:** belum ada tuning hyperparameter. Pemilihan jumlah cluster pada tahap lanjutan dilakukan dengan Cross-Validation pada data latih sehingga data uji tidak dipakai untuk memilih model. Data uji hanya dipakai untuk menghitung metrik pelaporan.

G.2 Metrik Evaluasi

Metrik	Arah	Alasan pemilihan
Silhouette [5]	Makin tinggi makin baik (maksimum 1)	Mengukur seberapa dekat tiap observasi dengan clusternya dibanding cluster lain; tidak memerlukan label
Davies-Bouldin [6]	Makin rendah makin baik	Mengukur rasio sebaran dalam cluster terhadap jarak antar cluster; pelengkap Silhouette
Calinski-Harabasz [7]	Makin tinggi makin baik	Rasio sebaran antar dan dalam cluster; nilainya bergantung pada jumlah data sehingga tidak sebanding antara data latih dan data uji
BIC dan AIC (khusus GMM)	Makin rendah makin baik	Membantu membandingkan jumlah komponen pada model probabilistik
Adjusted Rand Index (ARI)	1 = identik, sekitar 0 = hampir tidak berkaitan	Mengukur kemiripan pengelompokan antar dua model atau skenario fitur

G.3 Risiko dan Keterbatasan Evaluasi

- **Data leakage:** dicegah dengan melatih scaler dan PCA hanya pada data latih atau di dalam fold (lihat D.2).
- **Data deret waktu:** pembagian dan Cross-Validation dilakukan secara acak, sehingga jam yang berdekatan dapat terpisah antara data latih dan data uji. Hasil bisa tampak lebih baik daripada kondisi sebenarnya. Pembagian berdasarkan blok waktu direncanakan pada tahap lanjutan.
- **Agglomerative:** label data uji dan lipatan validasi diperoleh lewat centroid terdekat, sehingga tidak sepenuhnya sebanding dengan K-Means dan GMM.
- **Tanpa label:** kualitas cluster hanya dinilai dengan metrik internal dan interpretasi manual.

H. Initial Results and Analysis

H.1 Tabel Hasil Eksperimen Awal

Tabel berikut merangkum hasil baseline dan kedua model kandidat untuk k = 2 dan k = 3 dengan tiga metode validasi dan tiga metrik. Semua angka identik dengan output notebook (bagian V).

Model	Peran	k	Metode validasi	Silhouette	Davies-Bouldin	Calinski-Harabasz
K-Means	Baseline	2	Hold-out: data latih (6.719 jam)	0,101	3,317	496,294
K-Means	Baseline	2	Hold-out: data uji (1.680 jam)	0,101	3,230	108,386
K-Means	Baseline	2	5-Fold CV: rata-rata ± simpangan baku	0,100 ± 0,006	3,302 ± 0,057	99,055 ± 3,447
K-Means	Baseline	3	Hold-out: data latih (6.719 jam)	0,099	2,810	489,419
K-Means	Baseline	3	Hold-out: data uji (1.680 jam)	0,103	2,742	105,160
K-Means	Baseline	3	5-Fold CV: rata-rata ± simpangan baku	0,099 ± 0,005	2,806 ± 0,033	98,011 ± 3,772
GMM	Kandidat 1	2	Hold-out: data latih (6.719 jam)	0,112	4,289	323,599
GMM	Kandidat 1	2	Hold-out: data uji (1.680 jam)	0,113	4,371	66,042
GMM	Kandidat 1	2	5-Fold CV: rata-rata ± simpangan baku	0,100 ± 0,019	4,319 ± 0,175	64,406 ± 4,988
GMM	Kandidat 1	3	Hold-out: data latih (6.719 jam)	0,068	4,368	250,217
GMM	Kandidat 1	3	Hold-out: data uji (1.680 jam)	0,062	4,372	51,290
GMM	Kandidat 1	3	5-Fold CV: rata-rata ± simpangan baku	0,051 ± 0,042	4,270 ± 0,343	51,886 ± 5,127
Agglomerative	Kandidat 2	2	Hold-out: data latih (6.719 jam)	0,073	2,643	330,697
Agglomerative	Kandidat 2	2	Hold-out: data uji (1.680 jam)	0,119	2,611	101,794
Agglomerative	Kandidat 2	2	5-Fold CV: rata-rata ± simpangan baku	0,169 ± 0,023	3,397 ± 0,518	86,855 ± 11,933
Agglomerative	Kandidat 2	3	Hold-out: data latih (6.719 jam)	0,081	3,486	332,698
Agglomerative	Kandidat 2	3	Hold-out: data uji (1.680 jam)	0,109	3,266	89,081
Agglomerative	Kandidat 2	3	5-Fold CV: rata-rata ± simpangan baku	0,138 ± 0,028	2,997 ± 0,249	82,714 ± 7,521

Tabel 2. Hasil eksperimen awal. "5-Fold CV" berisi rata-rata ± simpangan baku pada lipatan validasi. Silhouette dan Calinski-Harabasz: makin tinggi makin baik; Davies-Bouldin: makin rendah makin baik. Nilai Agglomerative pada data uji diperoleh lewat centroid terdekat.

H.2 Kemiripan Pengelompokan Antar Model

k	K-Means vs GMM	K-Means vs Agglomerative	GMM vs Agglomerative
2	0,032	0,031	-0,019
3	0,006	0,195	0,299

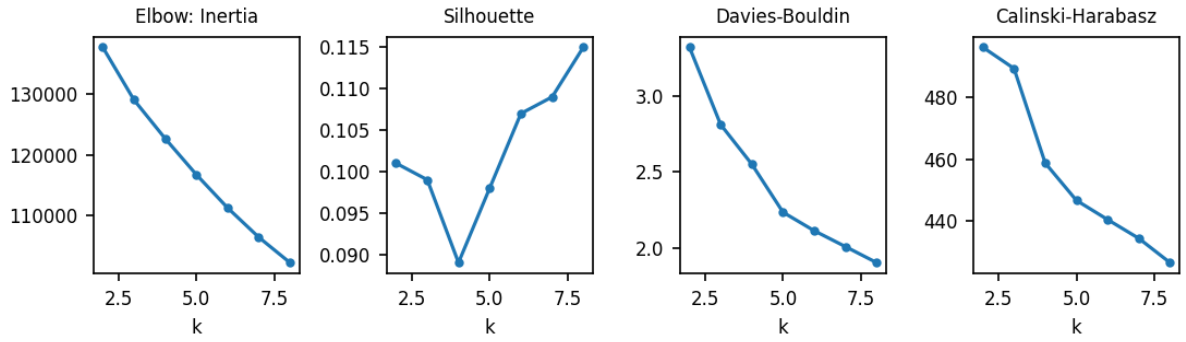
Tabel 3. Adjusted Rand Index antar model pada data latih.

Pada k=2, ARI mendekati 0 sehingga ketiga model membentuk kelompok yang hampir tidak berkaitan. Pada k=3, Agglomerative dan GMM lebih mirip (ARI 0,299), karena keduanya menemukan kelompok jam dengan perangkat aktif.

H.3 Kestabilan (5-Fold Cross-Validation)

Simpangan baku Silhouette antar fold adalah indikator kestabilan (Tabel 2, baris 5-Fold CV): K-Means paling stabil (0,005 sampai 0,006). GMM dengan k=3 paling tidak stabil (0,051 ± 0,042 dengan satu fold bernilai negatif, sekitar -0,012), sehingga kurang layak diandalkan. Agglomerative memiliki skor tertinggi (0,169 pada k=2) tetapi variasinya lebih besar (0,023 dan 0,028; Davies-Bouldin k=2 bervariasi 0,518). Sebagian nilai Agglomerative yang tinggi dapat berasal dari cara pelabelan lipatan lewat centroid terdekat.

H.4 Pemilihan Jumlah Cluster



Gambar 6. Elbow (Inertia), Silhouette, Davies-Bouldin, dan Calinski-Harabasz untuk K-Means pada k = 2 sampai 8.

k	Inertia	Silhouette	Davies-Bouldin	Calinski-Harabasz	BIC (GMM)	AIC (GMM)
2	137.648	0,101	3,317	496,3	207.235	203.481
3	129.015	0,099	2,810	489,4	109.699	104.065
4	122.674	0,089	2,550	458,8	47.887	40.372
5	116.748	0,098	2,235	446,7	38.977	29.582
6	111.302	0,107	2,114	440,5	26.420	15.145
7	106.473	0,109	2,010	434,4	25.151	11.996
8	102.303	0,115	1,905	426,5	23.012	7.977

Tabel 4. Pemilihan jumlah cluster pada data latih terstandar.

- **Elbow:** Inertia turun halus dari 137.648 (k=2) ke 102.303 (k=8) tanpa tekukan yang jelas.
- **Silhouette** semua rendah (0,089 sampai 0,115). Nilai tertinggi pada k=8 (0,115), tetapi selisihnya dengan k=2 (0,101) sangat kecil.
- **Davies-Bouldin** membaik terus sampai k=8 (1,905), sedangkan **Calinski-Harabasz** tertinggi pada k=2 (496,3) dan terus turun. Keduanya berlawanan arah.
- **BIC dan AIC GMM** turun terus sampai k=8 tanpa titik minimum, yang dapat berarti komponen tambahan menangkap lonjakan atau nilai ekstrem, bukan kelompok bermakna.
- **Kesimpulan:** metrik tidak sepakat dan tidak ada satu k yang jelas terbaik, sehingga klaim "k terbaik" tidak dibuat dari satu metrik saja.

H.5 Profil dan Ukuran Cluster

Profil K-Means dengan k=3 (rata-rata nilai asli pada data latih, Silhouette 0,099):

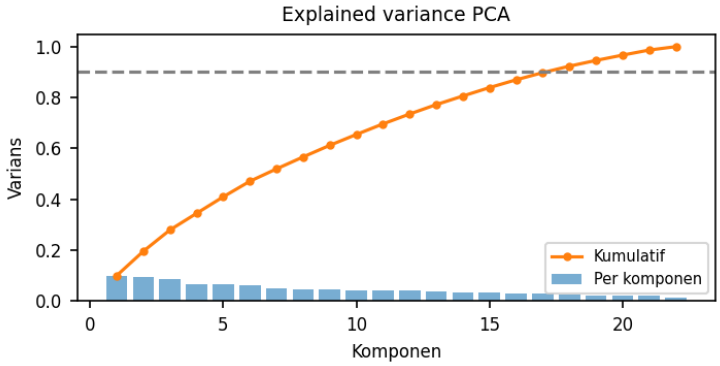
Cluster	Ukuran (jam)	Persen	Furnace 1 + 2 (kW)	Suhu (F)	Awan	Kelembapan	Bulan rata-rata
0	3.748	55,8%	0,042 + 0,083	60,8	0,14	0,65	7,0
1	1.953	29,1%	0,209 + 0,241	33,7	0,13	0,59	4,7
2	1.018	15,2%	0,102 + 0,132	46,4	0,73	0,87	6,7

Tabel 5. Ukuran dan profil cluster K-Means k=3 (cluster diberi nomor dari yang terbesar).

- Cluster 0: jam hangat dengan pemanas rendah dan cuaca cerah. Cluster 1: jam dingin dengan pemanas tinggi pada awal tahun. Cluster 2: jam berawan dan lembap dengan suhu sedang.
- Aktivitas perangkat rumah (Living room, Kitchen, Well, Microwave) hampir tidak berbeda antar cluster, sehingga pembagian ini terutama menggambarkan cuaca dan musim, bukan kebiasaan penggunaan perangkat.

Pada k=5 (Silhouette 0,098) terbentuk lima cluster berukuran 3.306, 1.573, 920, 821, dan 99 jam, yaitu jam hangat dan sepi (49,2%), jam dingin dengan pemanas tinggi (23,4%; Furnace 0,215 dan 0,252 kW), jam berawan (13,7%; awan 0,75), jam dengan perangkat aktif (12,2%; Living room 0,189 kW, Well 0,058, Microwave 0,040, Kitchen 14 0,038), dan satu cluster kecil Kitchen 12 (1,5%; 0,125 kW dibanding 0,001 sampai 0,002 kW pada cluster lain). Nilai Silhouette k=5 hampir sama dengan k=3; metrik tidak menunjukkan k=5 lebih baik, tetapi hasilnya lebih kaya untuk ditafsirkan terhadap tujuan project.

H.6 PCA



Gambar 7. Explained variance dan varians kumulatif PCA.

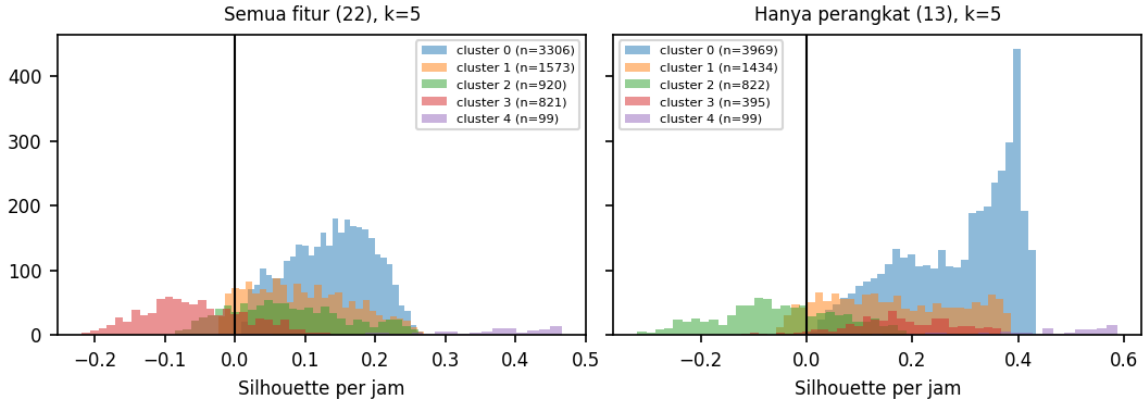
Komponen pertama hanya menjelaskan 9,9% varians dan komponen kedua 9,6% (kumulatif 19,5%). Untuk mempertahankan 80%, 90%, dan 95% varians dibutuhkan 14, 18, dan 20 komponen dari 22 fitur, sehingga data tidak memiliki struktur dimensi rendah yang kuat. Scaling dan PCA ditempatkan di dalam Pipeline dan dinilai pada ruang fitur yang sama (22 fitur terstandar).

Skenario	k	Dimensi	Silhouette	Davies-Bouldin	Calinski-Harabasz	ARI vs tanpa PCA
Tanpa PCA (22 fitur)	3	22	0,099	2,810	489,4	1,000
PCA 18 komponen	3	18	0,099	2,811	489,2	0,980
PCA 14 komponen	3	14	0,098	2,817	487,8	0,949
Tanpa PCA (22 fitur)	5	22	0,098	2,235	446,7	1,000
PCA 18 komponen	5	18	0,098	2,234	446,6	0,981
PCA 14 komponen	5	14	0,097	2,242	444,9	0,925

Tabel 6. Perbandingan K-Means dengan dan tanpa PCA.

Hasil clustering dengan PCA 14 sampai 18 komponen hampir sama dengan tanpa PCA (ARI 0,925 sampai 0,981) sehingga PCA tidak memperbaiki hasil, hanya sedikit mengurangi dimensi. Karena komponen PCA lebih sulit diinterpretasi daripada fitur asli padahal interpretasi cluster adalah tujuan utama, PCA tidak digunakan untuk model utama pada tahap ini. Kesimpulan ini hanya berlaku untuk k=3 dan k=5 serta 14 dan 18 komponen yang diuji.

H.7 Diagnosis Awal



Gambar 8. Sebaran Silhouette per jam pada K-Means k=5 untuk skenario semua fitur dan hanya perangkat.

Silhouette per jam bernilai negatif pada 964 dari 6.719 jam (14,3%) pada skenario semua fitur dan 706 jam (10,5%) pada skenario hanya perangkat. Sumber utamanya adalah cluster jam aktif: rata-rata Silhouette-nya negatif (-0,058 dan -0,052) dengan 68% sampai 78% jam bernilai negatif, artinya jam aktif tidak membentuk kelompok yang terpisah jelas, melainkan lebih menyerupai kelanjutan dari jam sepi dan jam pemanas. Cluster Kitchen 12 (99 jam) paling rapat dan tersebar pada 33 tanggal berbeda, sehingga merupakan pola berulang yang jarang. Analisis kesalahan yang lebih lengkap termasuk tahap lanjutan.

H.8 Temuan Awal dan Keterbatasan

1. **Ketiga model menghasilkan pengelompokan yang sangat berbeda.** K-Means memisahkan jam menurut musim (suhu dan pemanas), GMM memisahkan jam aktif dan jam sepi, dan Agglomerative memisahkan jam berawan dan lembap. GMM paling dekat dengan tujuan project (pola penggunaan perangkat).
2. **Tidak ada model yang unggul di semua metrik.** GMM memiliki Silhouette tertinggi pada hold-out (0,112), Agglomerative memiliki Davies-Bouldin terbaik (2,643), dan K-Means memiliki Calinski-Harabasz tertinggi (496,3) serta paling stabil.
3. **Struktur cluster belum tegas.** Semua nilai Silhouette di bawah sekitar 0,17, sehingga satu metrik tidak cukup untuk memilih model; profil cluster dan ARI lebih informatif.
4. **Fitur cuaca sangat memengaruhi hasil** padahal hanya pemanas, Wine cellar, dan Fridge yang berkorelasi dengan suhu; fitur waktu hampir tidak berpengaruh.
5. **Perlu diperbaiki:** pemilihan jumlah cluster yang sistematis, peran fitur cuaca, penanganan nilai ekstrem (misalnya Barn), strategi validasi untuk data deret waktu, dan penanganan cluster jam aktif yang batasnya kabur.

Keterbatasan: (a) interval 1 baris = 1 menit dan zona waktu UTC-5 adalah asumsi dari pola data; (b) pembagian dan Cross-Validation acak pada data deret waktu dapat membuat hasil tampak terlalu baik; (c) nilai evaluasi data uji Agglomerative tidak langsung sebanding karena memakai centroid terdekat; (d) hanya k = 2 dan 3 yang diuji pada ketiga model; (e) tidak ada label kebenaran sehingga evaluasi hanya memakai metrik internal; (f) DBSCAN belum diuji.

I. Documentation and Next Plan

I.1 Dokumentasi dan Keterlacakan

- **Notebook:** B04_PolaPenggunaanPerangkatRumahPintar_UTS_Milestone1.ipynb (Google Colab); tautan dikumpulkan melalui formulir pengumpulan. Dijalankan dengan Runtime, Jalankan semua, dan tidak memerlukan unggahan file karena dataset diunduh otomatis dari Kaggle (butuh koneksi internet).
- **Keterlacakan:** semua angka pada laporan ini diambil dari output notebook. Hasil memakai random_state = 42 sehingga dapat direproduksi. Versi library tercatat pada notebook bagian Q.

- **Urutan bagian notebook:** A-B (masalah dan dataset), C dan C2 (preprocessing dan feature engineering), D-F (baseline), G-I (kandidat model), J-M (validasi dan kestabilan), N-Q (jumlah cluster, PCA, catatan eksperimen), R-T (seleksi fitur, diagnosis, analisis error), U (EDA), V-W (tabel hasil dan rencana pasca-UTS).
- **Sumber dataset:** Kaggle, taranvee, Smart Home Dataset with Weather Information, file HomeC.csv [3].

I.2 Catatan Parameter, Random Seed, dan Metrik

Komponen	Pengaturan
Dataset	Smart Home Dataset with Weather Information (Kaggle, taranvee), file HomeC.csv
Unit observasi	Satu jam (rata-rata dari data per menit), 8.399 observasi
Fitur	22: 13 perangkat, 6 cuaca, 3 waktu (hour_sin, hour_cos, weekend)
Pembagian data	Acak 80% latih (6.719) dan 20% uji (1.680), random_state = 42
Scaling	StandardScaler, dilatih hanya pada data latih (di dalam Pipeline atau di dalam tiap fold)
K-Means	n_init = 10, random_state = 42, k = 2 sampai 8
GMM	covariance_type = full, n_init = 5, random_state = 42, k = 2 sampai 8
Agglomerative	linkage = ward, k = 2 dan 3, label data uji lewat centroid terdekat
PCA	14 dan 18 komponen, random_state = 42, di dalam Pipeline
Validasi	Hold-out 80/20 dan 5-Fold Cross-Validation (shuffle = True, random_state = 42) pada data latih
Metrik	Silhouette, Davies-Bouldin, Calinski-Harabasz, BIC dan AIC (GMM), ARI antar model
Versi library	Lihat output sel kode di atas

I.3 Rencana Pekerjaan Setelah UTS Menuju UAS

Rencana berikut disusun dari temuan awal Milestone 1 dan setiap butir dikaitkan dengan bukti pada notebook.

No	Pekerjaan	Dasar temuan	Keluaran
1	Memilih jumlah cluster secara sistematis dan memperluas pencarian ke k lebih besar	Metrik tidak sepakat (Calinski-Harabasz terbaik pada k=2, Davies-Bouldin dan BIC terus membaik sampai k=8, Silhouette hampir datar); k=5 menghasilkan cluster yang lebih kaya makna (notebook bagian N dan O)	Tabel pemilihan k dengan Cross-Validation dan pertimbangan interpretabilitas
2	Memperbaiki fitur: membuang atau menguji ulang fitur waktu dan Garage door, serta mentransformasi fitur yang miring (misalnya log atau pemotongan nilai ekstrem)	Fitur waktu hampir tidak mengubah hasil (ARI 0,91 sampai 0,94, bagian R); Garage door hampir konstan dan sebaran perangkat sangat miring (notebook bagian U); Barn tidak terwakili oleh cluster mana pun (notebook bagian T)	Perbandingan hasil sebelum dan sesudah perbaikan fitur
3	Menentukan peran fitur cuaca: membandingkan secara adil pengelompokan dengan dan tanpa cuaca	Cuaca mengubah pengelompokan besar (ARI sekitar 0,35 sampai 0,51 tanpa cuaca) dan hanya pemanas, Wine cellar, dan Fridge yang berkorelasi dengan suhu (notebook bagian R dan U)	Keputusan fitur beserta bukti, dengan metrik yang dihitung pada ruang evaluasi yang sama
4	Memperbaiki strategi validasi untuk data deret waktu: pembagian berdasarkan blok waktu dan validasi berurutan	Pembagian acak membuat jam berdekatan terpisah antara data latih dan uji, sehingga hasil bisa tampak terlalu baik (notebook bagian J dan M)	Perbandingan hasil pembagian acak dan berbasis waktu
5	Menangani cluster jam aktif yang batasnya kabur: mencoba model dengan keanggotaan lunak (GMM dengan variasi kovarians) dan jumlah cluster lain	67,8% jam pada cluster jam aktif bernilai Silhouette negatif dan sebagian besar paling mirip jam sepi (notebook bagian S dan T)	Evaluasi cluster jam aktif dengan probabilitas keanggotaan
6	Menguji algoritma tambahan seperti DBSCAN dan variasi linkage Agglomerative	Cluster kecil (Kitchen 12, 99 jam) dan nilai ekstrem menunjukkan bentuk cluster tidak seragam (notebook bagian T)	Tabel perbandingan algoritma tambahan terhadap baseline
7	Menguji kestabilan lebih menyeluruh: variasi random seed, jumlah fold, dan ukuran data uji	GMM k=3 tidak stabil (Silhouette 0,051 ± 0,042, satu fold negatif) dan Agglomerative bervariasi lebih besar (notebook bagian K)	Ringkasan kestabilan tiap model

No	Pekerjaan	Dasar temuan	Keluaran
8	Tuning menyeluruh dan pemilihan model final dengan bukti berganda (tidak berdasarkan satu metrik atau visualisasi)	Tidak ada model yang unggul di semua metrik (notebook bagian H dan V)	Model final beserta alasan metodologis dan keterbatasan
9	Menyusun interpretasi akhir cluster sebagai pola penggunaan perangkat dan mendokumentasikan batasannya	Cluster berbasis perangkat lebih mudah ditafsirkan (notebook bagian O dan R)	Profil cluster akhir dan implikasinya
10	Menyempurnakan laporan, notebook, dan bahan presentasi	Persyaratan UAS	Laporan UAS, notebook final, dan slide presentasi

- **Tahap 1:** butir 2, 3, dan 4 (perbaikan fitur dan validasi), karena memengaruhi semua eksperimen berikutnya.
- **Tahap 2:** butir 1, 5, 6, dan 7 (pemilihan k, model tambahan, dan kestabilan).
- **Tahap 3:** butir 8 dan 9 (tuning, pemilihan model final, dan interpretasi).
- **Tahap 4:** butir 10 (finalisasi laporan dan presentasi).
- Dataset dan masalah tidak diganti. Perubahan hanya pada fitur, model, dan strategi evaluasi. Semua klaim pada tahap berikutnya harus didukung bukti dari notebook, bukan hanya dari visualisasi atau satu metrik.

Daftar Pustaka

[1] Barker, S., Mishra, A., Irwin, D., Cecchet, E., Shenoy, P., & Albrecht, J. (2012). Smart*: An open data set and tools for enabling research in sustainable homes. *Proceedings of the Workshop on Data Mining Applications in Sustainability (SustKDD)*, Beijing.

[2] Rajabi, A., Eskandari, M., Jabbari Ghadi, M., Li, L., Zhang, J., & Siano, P. (2020). A comparative study of clustering techniques for electrical load pattern segmentation. *Renewable and Sustainable Energy Reviews*, 120, 109628. https://doi.org/10.1016/j.rser.2019.109628

[3] taranvee. *Smart Home Dataset with Weather Information* [Data set]. Kaggle. https://www.kaggle.com/datasets/taranvee/smart-home-dataset-with-weather-information (diakses 2 November 2026).

[4] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

[5] Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53-65.

[6] Davies, D. L., & Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-1(2), 224-227.

[7] Calinski, T., & Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics*, 3(1), 1-27.